

Research Report: Architecture d'Aggrégation et Benchmarking Anonymisé

Date: 2026-05-21 **Author:** Mahmoud **Research Type:** technical

1. Processus d'Extraction et Anonymisation (Pipeline ETL)

L'architecture repose sur un principe de **Data Exfiltration Sécurisée** : les données quittent le schéma isolé du tenant uniquement sous forme agrégée et anonymisée.

Étapes du Pipeline

1. **Extraction Locale (Per Schema)** : Un worker SQL calcule des KPIs prédéfinis au sein de chaque schéma (ex: `AVG(days_to_pay)`).
 2. **Anonymisation stricte** :
 - Suppression de tous les champs PII (Personally Identifiable Information) : noms de clients, fournisseurs, adresses.
 - Hachage des IDs pour permettre un suivi temporel anonyme sans révéler l'identité réelle.
 3. **Généralisation Sectorielle** : Les données sont taguées avec un code secteur (ex: "Industrie Textile") et une région, mais sans le nom de la PME.
-

2. Infrastructure de Benchmarking (Global Layer)

Toutes les données anonymisées sont consolidées dans un schéma PostgreSQL dédié : `global_aggregator`.

Data Model Global

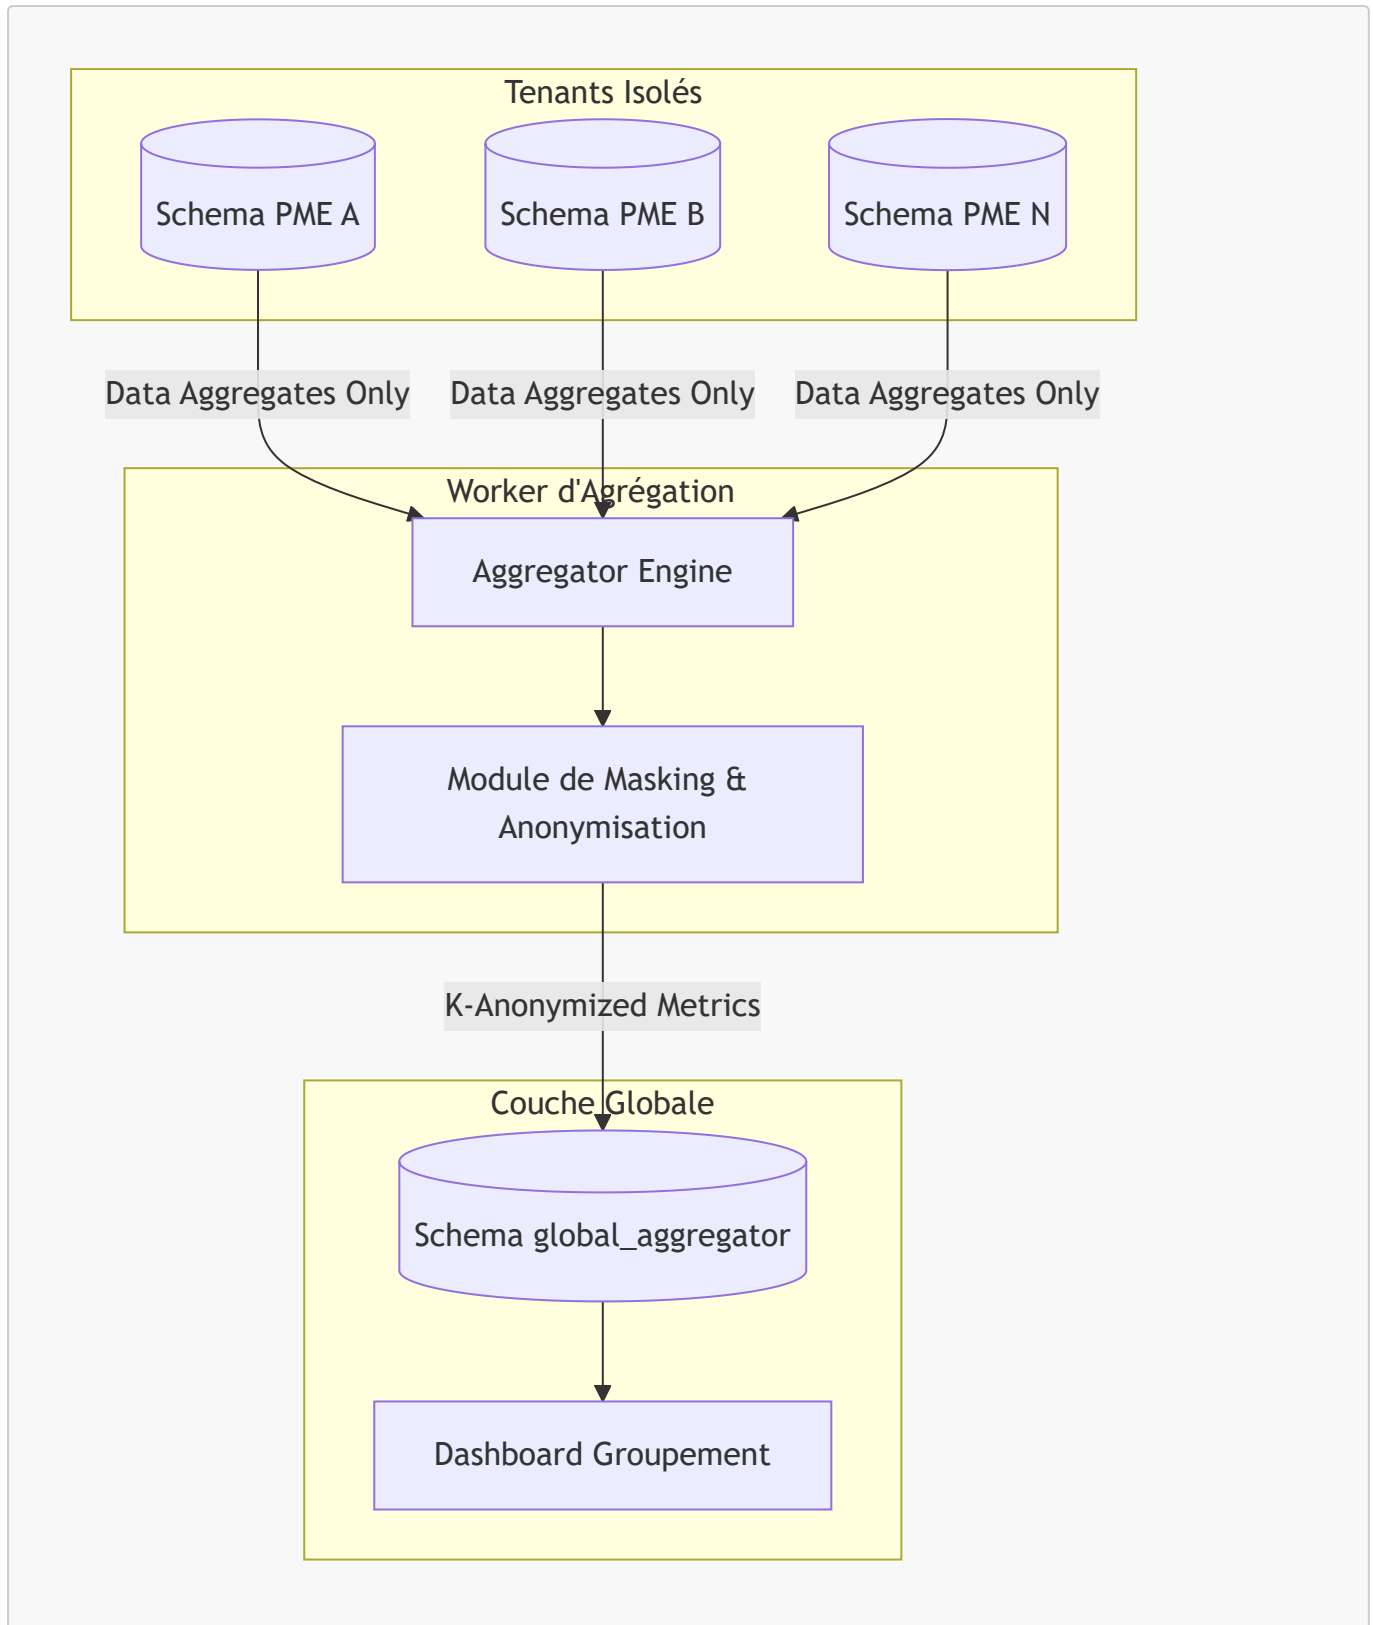
- **Table `sector_benchmarks`** : Stocke les moyennes et centiles par secteur d'activité.
- **Table `anonymized_tenant_performance`** : Permet à une PME de comparer ses propres KPIs (via son `tenant_id_hash`) par rapport aux autres, sans savoir qui sont les autres.

Sécurité & Confidentialité (K-Anonymity)

Pour éviter qu'on puisse deviner l'identité d'une PME dans un secteur peu représenté, nous appliquons la règle du **K-Anonymat** :

Un benchmark sectoriel ne s'affiche que si au moins **5 PME distinctes** de ce secteur ont fourni des données. En dessous de ce seuil, les données sont fondues dans une catégorie "Autres secteurs".

Architecture Diagram: Benchmarking & Aggregation Flow



Next Steps: Synthesis of Final Technical Architecture

Toutes les briques technologiques critiques ont été étudiées :

- **Isolation** : Multi-schéma PostgreSQL.
- **IA** : Orchestration Ollama par session.
- **Flux** : Ingestion asynchrone n8n + RabbitMQ.
- **Intelligence** : Benchmarking anonymisé via ETL sécurisé.

Nous pouvons maintenant passer à la conception de l'**Architecture Technique Finale**.